Map Reduce, Hadoop y Spark

Juan F. Pérez

Departamento MACC
Matemáticas Aplicadas y Ciencias de la Computación
Universidad del Rosario

juanferna.perez@urosario.edu.co

2018

Contenidos

Map Reduce

Map Reduce

- Google paper (2004)
- Modelo de procesamiento de datos en paralelo
- Ejecución dividida en dos grandes etapas

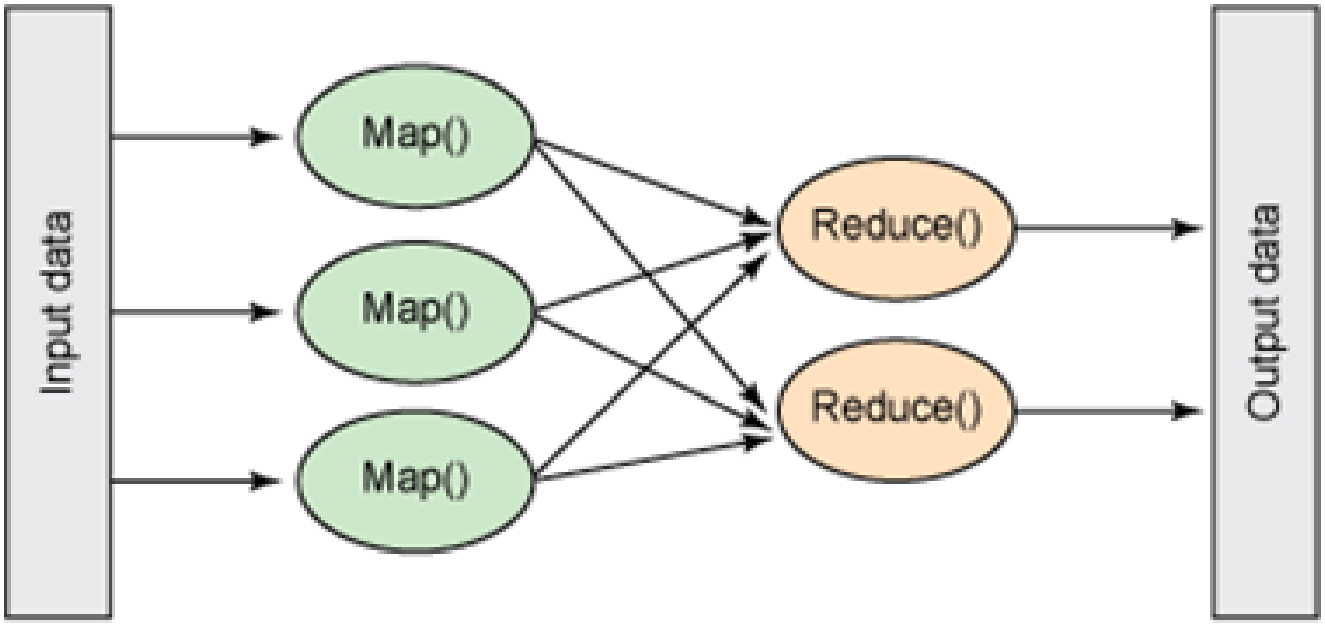

Map Reduce

¿Por qué Google?

Número de páginas web:

1991: 1 (WWW)

1995: 23,500 (Altavista, Amazon)

1998: 2,410,067 (Google)

2005: 64,780,610 (YouTube)

2010: 206,956,763 (Pinterest)

Hoy: $>$ 1,259,155,000

Ejemplo Contar Palabras

- Contar cuántas veces aparece cada palabra en millones de documentos
- Cada nodo toma unos cuantos documentos y cuenta las palabras en ellos (Map)
- Cada nodo saca el total para un grupo de palabras (Reduce)

De Map Reduce a Hadoop y más allá

- Apache Hadoop 0.1.0 (Abril 2006)
- 

- Yahoo corre cluster Hadoop con 1000 máquinas (Octubre 2006)
- Yahoo crea Pig (2007): lenguaje de alto nivel para análisis de datos estilo Map Reduce
- 

De Map Reduce a Hadoop y más allá

- Apache Hive (2008):HiveQL: lenguaje estilo SQL para acceder a datos almacenados en Hadoop (HDFS)
- 

De Map Reduce a Hadoop y más allá

- Apache Hive (2008):HiveQL: lenguaje estilo SQL para acceder a datos almacenados en Hadoop (HDFS)
- 

- HDFS: Hadoop Distributed File System

De Map Reduce a Hadoop y más allá

- Apache Hive (2008):HiveQL: lenguaje estilo SQL para acceder a datos almacenados en Hadoop (HDFS)
- 

- HDFS: Hadoop Distributed File System

- YARN: Yet Another Resource Negotiator - Hadoop 2.0 (2013) 

De Map Reduce a Hadoop y más allá

- Apache Spark (2014) 

- Desarrollado en Berkeley por Matei Zaharia (2009) en AMPLab
- Donado a la funcación Apache (2013)

De Map Reduce a Hadoop y más allá

- Apache Spark (2014) 

- Desarrollado en Berkeley por Matei Zaharia (2009) en AMPLab
- Donado a la funcación Apache (2013)
- Versión 1.6 (2016/01)
- Versión 2.0 (2016/07)
- Versión 2.1 (2016/12)
- Versión 2.2 (2017/07)

De Map Reduce a Hadoop y más allá

- Apache Spark (2014) 

- Desarrollado en Berkeley por Matei Zaharia (2009) en AMPLab
- Donado a la funcación Apache (2013)
- Versión 1.6 (2016/01)
- Versión 2.0 (2016/07)
- Versión 2.1 (2016/12)
- Versión 2.2 (2017/07)
- Versión 2.3 (2018/02)
- Versión 2.3.2 (2018/09)

Apache Spark

Apache Spark

Hadoop cuenta con excelentes herramientas para:

- Administración clústers (YARN)
- Manejo de archivos distribuidos (HDFS)

Apache Spark

Hadoop cuenta con excelentes herramientas para:

- Administración clústers (YARN)
- Manejo de archivos distribuidos (HDFS)
- Lenguajes de alto nivel (Pig, Hive, etc)

Apache Spark

Motivaciones

- Hadoop está muy atado al paradigma Map Reduce
- Flujo de datos lineal: Map + Reduce + Algunas etapas adicionales

Apache Spark

Motivaciones

- Hadoop está muy atado al paradigma Map Reduce
- Flujo de datos lineal: Map + Reduce + Algunas etapas adicionales
- Requerimiento de flujos de ejecución más complejos
- Requerimiento de examinar datos repetidamente (algoritmos iterativos)

Apache Spark

Motivaciones

- Hadoop está muy atado al paradigma Map Reduce
- Flujo de datos lineal: Map + Reduce + Algunas etapas adicionales
- Requerimiento de flujos de ejecución más complejos
- Requerimiento de examinar datos repetidamente (algoritmos iterativos)
- En Hadoop resultados de cada etapa almacenados en disco
- Almacenar en memoria mucho más veloz

Apache Spark

Motivaciones

- Hadoop está muy atado al paradigma Map Reduce
- Flujo de datos lineal: Map + Reduce + Algunas etapas adicionales
- Requerimiento de flujos de ejecución más complejos
- Requerimiento de examinar datos repetidamente (algoritmos iterativos)
- En Hadoop resultados de cada etapa almacenados en disco
- Almacenar en memoria mucho más veloz
- Análisis de flujos de datos (además del procesamiento en lotes)

Apache Spark - Librerias

Spark SQL: manejo de datos estructurados

Spark Streaming: manejo de flujos de datos

MLlib: algoritmos de aprendizaje de máquina

GraphX: análisis de datos representados como grafos

El ecosistema Hadoop/Spark

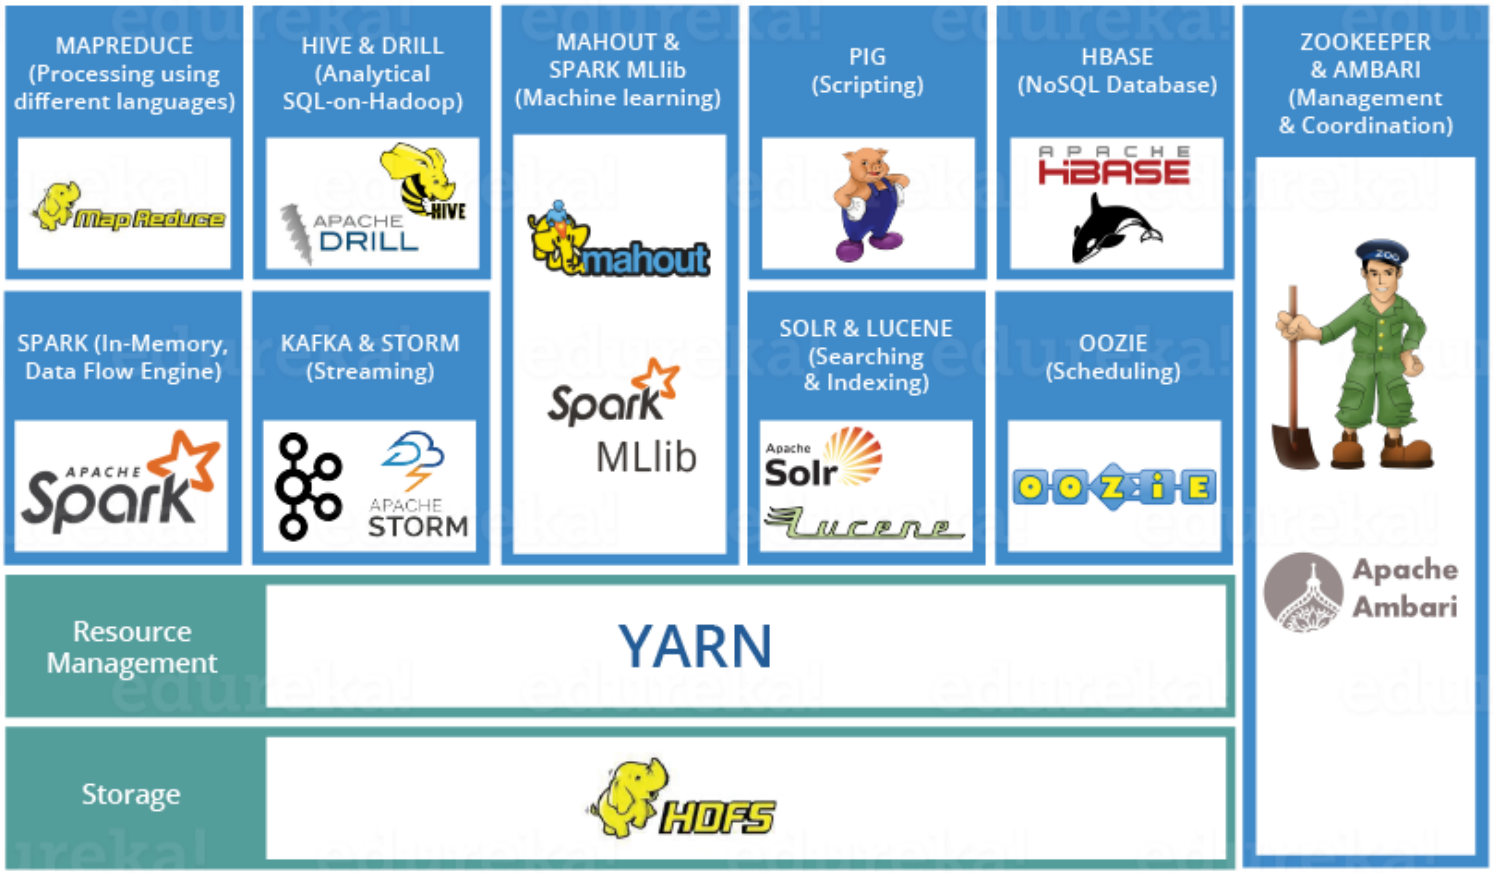

Arquitectura Lambda

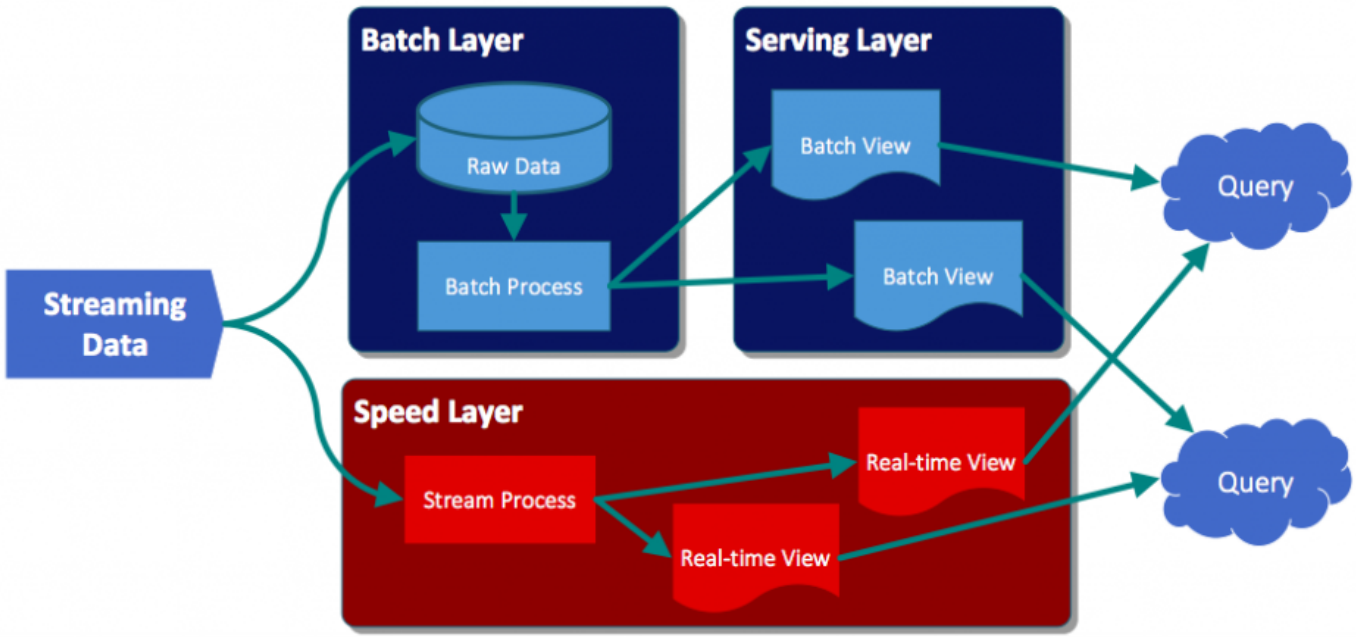

Trabajando con Apache Spark

Trabajando con Apache Spark

- Spark desarrollado en Scala
- Ofrece APIs para Scala, Java, Python, R
- Python: `pyspark`
- Módulos:
  - Principal
  - SQL
  - Streaming
  - ML

Pyspark: Módulo principal

SparkContext

- Clase principal del módulo
- Ofrece la funcionalidad de Spark
- Conexión con el clúster de Spark
- Permite crear estructuras de datos (**RDDs**)

Estructuras de Datos en Spark: RDDs

RDD: Resilient Distributed Dataset

- Colección distribuida de objetos
- Inmutable
- Cada partición contiene un subconjunto de objetos
- Creación: cargar un set de datos externos, o distribuir una colección local

Estructuras de Datos en Spark: Dataframes y Datasets

- Introducidos en versiones más recientes de Spark
- Abstracción de más alto nivel (preferibles a trabajar directamente con RDDs)
- Internamente representados como RDDs

Dataframe:

- Colección distribuida de tipos `Row`
- Datos como filas de una tabla con valores por columna
- Datos sin tipos (simplemente `Row`)
- Similar a los dataframes en pandas

Estructuras de Datos en Spark: Dataframes y Datasets

Dataset:

- Colección distribuida de tipos de datos fijos
- Tipo de los datos definidos como una clase de caso en Scala o una clase en Java
- Similar a DataFrame pero con tipos de datos fijos
- Desde Apache 2.0, DataFrame es implementado como un Dataset con tipo de datos `Row`

Pyspark: Módulo principal

`SparkContext`:

- `parallelize(c, numSlices=None)`: distribuye una colección local *c* para construir un RDD con numSlices particiones.
- `range(start, end=None, step=1, numSlices=None)`: crea un RDD de enteros de start a end con incrementos de step, alamacenado en un número de particiones numSlices
- `union(rdds)`: crea la unión de una lista de RDDs
- `textFile(name, minPartitions=None, use_unicode=True)`: lee un archivo de texto (desde HDFS, local, etc) y retorna un RDD de Strings. Puede definir el número mínimo de particiones y si el texto usa unicode o no.

Trabajando con Spark y Pyspark

- Escribimos código en lenguaje Python
- El código se ejecuta en un cluster

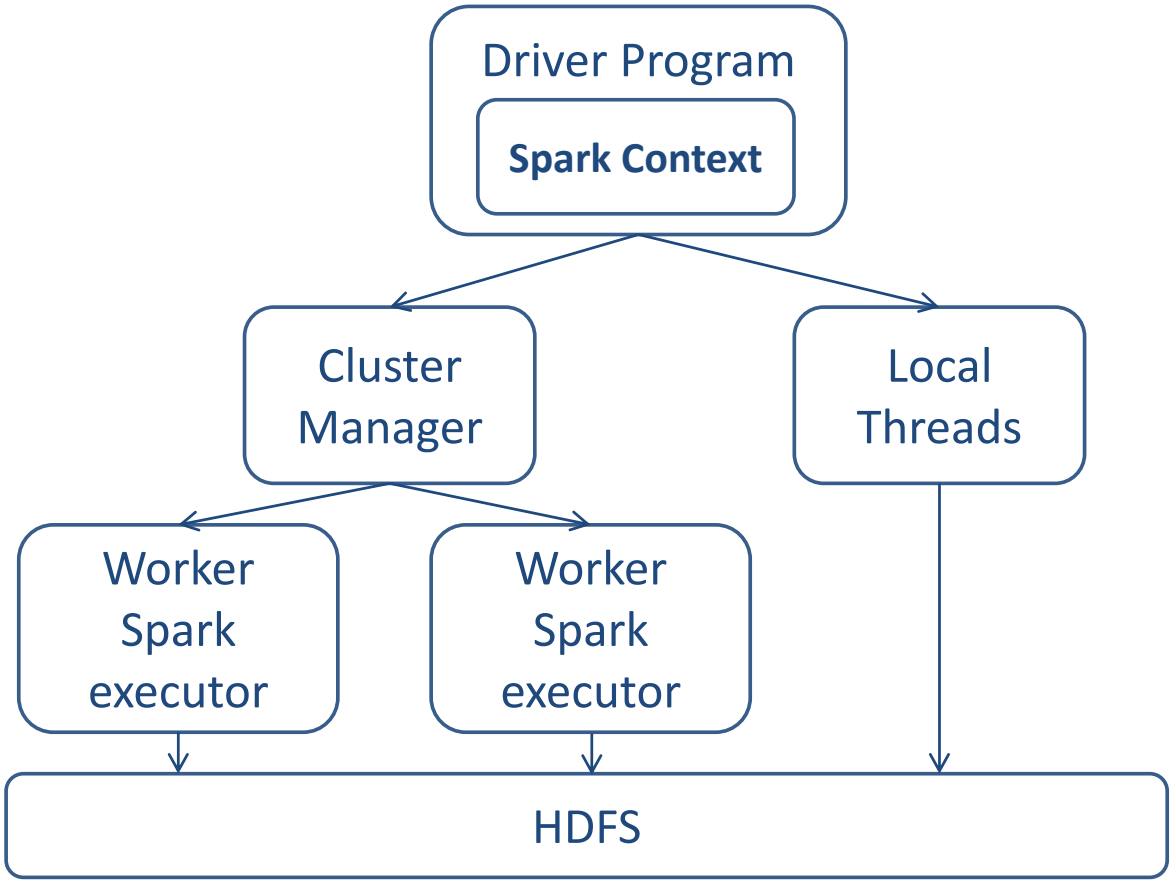

Trabajando con Spark y Pyspark

- Setup de cluster es una tarea compleja
- Requiere setup del cluster manager y workers
- Alternativa: *Databricks*

Databricks

Databricks

- Plataforma administrada
- Cluster en la nube (Amazon)
- `https://community.cloud.databricks.com`
- Crear cuenta

Databricks UI

- databricks
- home
- workspace
- recent
- data
- clusters
- jobs
- search

Notebooks (Workspace)

- `Workspace`, `Create`, `Notebook`
- Compuestos de celdas donde escribimos código en: Python, R, Scala, SQL, Markdown
- Celda con lenguaje por defecto, puede reemplazarse con e.g., %python
- Conectar cuaderno a un cluster para ejecutar comandos
- Conexión no es permanente
- Cuadernos se pueden programar como trabajos para correr un pipeline

```
a = range(10)
print(a)
b = sum(a)/len(a)
print(b)
```

Clusters

- `Cluster`, `CreateCluster`
- Revisar versiones de Scala
- Revisar tipo de recurso
- `CreateCluster`, esperar a que esté listo
- Conectar cuaderno a un cluster para ejecutar comandos
- Volver a `Workspace`, `Detached`, `Attach to`
- En la celda `Shift+Enter`

```
spark
```

Clusters

- Grupos de computadores donde se ejecuta e código
- La idea es usarlos como si fueran un solo computador
- Ejecutar código de cuadernos sobre datos
- Datos deben estar disponibles en el clúster (HDFS/DFDS, AmazonS3)

Data

- `Data`, `Tables`, `+`
- `Upload File`, arrastrar el archivo a subir
- `Create Table with UI`
- Seleccionar Cluster
- Primera fila con encabezados
- Especificar Atributos (tipos)
- `Create Table`

Trabajando con PySpark

Trabajando con PySpark

spark

Construyendo DataFrames

```
data = [('Juan', 20), ('Camilo', 25), ('Sara', 32),
 ('Marta', 35)]
df = spark.createDataFrame(data)
```

```
df = spark.createDataFrame(data, ['nombre', 'edad'])
```

Selccionando Columnas

```
colEdad = df.edad
```

```
df.select('*')
```

```
df2 = df.select('nombre', 'edad')
```

```
df2 = df.select(df.nombre, df.edad)
```

Seleccionando y Operando Columnas

```
df2 = df.select(df.nombre, (df.edad+20).alias('edad'))
df2.show()
```

Removiendo Columnas

```
df3 = df2.drop(df2.edad)
df3.show()
```

Funciones Lambda

Función

- Simple
- Sin nombre
- Útil para definir operaciones simples a aplicar a doto un set de datos (e.g., columna de un DataFrame)

Ejemplo:

```
lambda s: s*2
```

Funciones Lambda

```
from pyspark.sql.types import IntegerType
duplicar = udf(lambda s: s*2, IntegerType())
df5 = df.select(df.nombre, duplicar(df.edad)
.alias('edad') )
df5.show()
```

Filtros

```
df6 = df5.filter(df5.edad > 45)
df6.show()
```

Eliminando Duplicados

```
data2 = data
data2.append(('Marta', 35))
display(data2)
```

```
df7 = spark.createDataFrame(data2, ['nombre', 'edad'])
df8 = df7.distinct()
df8.show()
```

Ordenando

```
df9 = df8.sort('edad')
df9.show()
```

```
df10 = df8.sort('edad', ascending=False)
df10.show()
```

Ordenando

```
datax = [('Juan', 20), ('Camilo', 25), ('Sara', 32),
 ('Marta', 35),('Carlos', 25),('Camila', 25)]
dfx= spark.createDataFrame(data, ['nombre', 'edad'])
dfx = dfx.sort('edad','nombre')
dfx.show()
```

Explode

```
from pyspark.sql import Row
data3 = [Row(a=1, listaEnteros=range(1,6) )]
df11 = spark.createDataFrame(data3)
df11.show()
```

Explode

```
from pyspark.sql.functions import explode
df12 = df11.select( df11.a, explode(df11.listaEnteros)
  .alias('enteros') )
df13 = df12.select(df12.enteros)
df11.show()
df12.show()
df13.show()
```

Agrupando y Contando

```
data4 = [('Juan', 20, 1200), ('Camilo', 25, 10000),
 ('Sara', 32, 2500),
 ('Marta', 35, 3000), ('Camilo', 45, 5000)]
df14 = spark.createDataFrame(data4,
 ['nombre', 'edad', 'Balance'])
df14.show()
```

```
df15 = df14.groupBy(df14.nombre)
df15 = df15.agg({"*": "count"} )
df15.show()
```

Agrupando y Contando

```
df16 = df14.groupBy(df14.nombre).count()
df16.show()
```

Calculando un promedio

```
df17 = df14.groupBy().avg()
df17.show()
```

```
df18 = df14.groupBy('nombre').avg('edad', 'balance')
df18.show()
```

Mostrando parte de los datos

```
df19 = spark.createDataFrame(data, ['nombre', 'edad'])
df19.collect()
```

```
df19.take(3)
```

```
display(df19.take(3))
```

Calculando Algunas Estadísticas Descriptivas

```
df19.describe().show()
```

Importando Archivos

Después de subir un archivo de texto, e.g., `pennylane.txt`

```
dataPath = "/FileStore/tables/pennylane.txt"
texto = spark.read.text(dataPath)
texto.show()
print(texto.count())
from pyspark.sql.types import IntegerType
longitud = udf(lambda s: len(s), IntegerType())
textoDf1 = texto.select(longitud(texto.value)
  .alias('long') )
textoDf1.show()
```

Importando Archivos

Después de subir un archivo de texto, e.g., `pennylane.txt`

```
texto = spark.read.text(dataPath)
from pyspark.sql.types import IntegerType
longitud = udf(lambda s: len(s), IntegerType())
textoDf2 = texto.filter(longitud(texto.value)>80)
textoDf2.show()
print(texto.count(), textoDf2.count())
```

Importando Archivos

Después de subir un archivo de texto, e.g., `pennylane.txt`

```
texto = spark.read.text(dataPath)
texto.cache()
from pyspark.sql.types import BooleanType
contarPenny =
 udf(lambda s: "pennylane" in s, BooleanType())
textoDf3 = texto.filter(contarPenny(texto.value))
textoDf3.show()
print(texto.count(), textoDf3.count(),
 textoDf3.first())
```

Importando Archivos CSV

Subir un archivo CVS, e.g., `secop.csv`

- Tipos de datos en columnas
- Encabezados
- Tabla

```
dataPath = "/FileStore/tables/SECOP2.csv"
secop = spark.read.format("com.databricks.spark.csv")
  .option("header","true")
  .option("inferSchema","true")
  .load(dataPath)
```

Transformaciones y Acciones

Transformaciones

Operaciones que **NO** se ejecutan cuando se ejecuta la celda

- Spark no las ejecuta inmediatamente
- Almacena el plan de ejecución
- Acumula todas las transformaciones que pueda hasta que se llama un acción
- Ejecución Perezosa
- Ejemplos: convertir tipos (int a float), filtrar valores, select, distinct, groupBy, sum, orderBy, filter, limit

Acciones

Operaciones que **SI** se ejecutan cuando se ejecuta la celda

- Spark ejecuta la acción inmediatamente
- Ejecuta también todas las transformaciones almacenadas
- Ejemplos: show, , count, collect, save

Transformaciones y Acciones

Beneficios:

- Spark aprovecha el plan completo para planear mejor la ejecución
- Explota oportunidades de paralelización
- Considera etapas de ejecución
- Grafo con múltiples etapas
- Resultados solo son retornados al nodo maestro al terminar todo el cálculo

Ejemplo

```
data = [('Juan', 20), ('Camilo', 25), ('Sara', 32),
 ('Marta', 35)]
df = spark.createDataFrame(data, ['nombre', 'edad'])
```

```
from pyspark.sql.types import IntegerType
duplicar = udf(lambda s: s*2, IntegerType())
df5 = df.select(df.nombre, duplicar(df.edad)
 .alias('edad') )
```

```
df6 = df5.filter(df5.edad > 45)
```

```
df6.show()
```

Transformaciones y Acciones

Exploremos la ejecución de los trabajos

- `Spark jobs`
- `View`
- `DAG Visualization`
- DAG: directed acyclic graph

Graficando datos

Graficando datos (DataFrame): display

```
dataPath = "/databricks-datasets/Rdatasets/data-001/\
csv/ggplot2/diamonds.csv"
diamonds = spark.read\
.format("com.databricks.spark.csv")\
.option("header","true")\
.option("inferSchema","true")\
.load(dataPath)\
diamonds.show()
```

```
display(diamonds)
```

Un ejemplo: contar palabras

Contar palabras

```
dataPath = "/FileStore/tables/karamazov.txt"
texto = spark.read.text(dataPath)
lineas = texto.rdd.map(lambda r: r[0])
```

Contar palabras

```
from operator import add
cuentas = lineas\
.flatMap(lambda x: x.split(' '))\
.map(lambda x: (x, 1))\
.reduceByKey(add)
```

Contar palabras

```
output = cuentas.collect()
outputDF = spark\
.createDataFrame(output, ['palabra', 'cuenta'])
outputDF = outputDF\
.sort(['cuenta', 'palabra'], ascending = False)
outputDF.show()
display(outputDF.take(200))
```

Ejemplo: regresión lineal

Cargar datos de un archivo CSV

```
data = spark.read.format("com.databricks.spark.csv")\
  .option("header", "true")\
  .option("inferSchema", "true")\
  .load("/databricks-datasets/samples/\
        population-vs-price/data_geo.csv")
data.cache()
data.count()
```

```
display(data)
```

Descartar datos nulos

```
data = data.dropna()
data.count()
```

```
display(data)
```

Seleccionar columnas relevantes

```
data2 = data.select('2014 Population estimate',\
 ('2015 median sales price'))
display(data2)
```

Seleccionar features para el análisis

```
from pyspark.ml.linalg import Vectors
from pyspark.ml.feature import VectorAssembler

assembler = VectorAssembler(\
inputCols=["2014 Population estimate"],\
outputCol = "features")
output = assembler.transform(data2)
display(output.select("features",\
 "2015 median sales price"))
output.show()
```

Marcar columna como label

```
output2 = output.selectExpr(\
"`2015 median sales price` as label", \
"features as features")
display(output2)
```

Definir y ajustar un modelo de regresión lineal

```
from pyspark.ml.regression import LinearRegression
lr = LinearRegression()
modelo = lr.fit(output2)
```

Calcular predicciones

```
prediccion = modelo.transform(output2)
display(prediccion)
```

Evaluar el modelo: error cuadrático medio

```
from pyspark.ml.evaluation import RegressionEvaluator
evaluator = RegressionEvaluator(metricName="rmse")
RMSE = evaluator.evaluate(prediccion)
print("Root Mean Squared Error = " + str(RMSE))
```

Usar pandas para preparar datos para graficar

```
from pandas import *
from ggplot import *

pob = output2.rdd.map(lambda p: (p.features[0]))\
.collect()
precio = output2.rdd.map(lambda p: (p.label))\
.collect()
pred = prediccion.select("prediction").rdd\
.map(lambda r: r[0]).collect()

pDF = DataFrame({'poblacion':pob,\
'precio':precio,'prediccion':pred})
print(pDF)
```

Usar ggplot para graficar

```
from ggplot import *

p = ggplot(pDF, aes('poblacion','precio')) \
+ geom_point(color='blue') \
+ geom_line(pDF, aes('poblacion','prediccion'), \
color='red') \
+ scale_x_log10() + scale_y_log10()
display(p)
```

Más sobre ggplot

http://ggplot.yhathq.com/

Un poquito de SQL y gráficos

Cargar datos de un archivo CSV

```
data = spark.read.format("com.databricks.spark.csv")\
   .option("header", "true")\
   .option("inferSchema", "true")\
   .load("/databricks-datasets/samples/\
          population-vs-price/data_geo.csv")
data.cache()
```

Limpiar y Registrar Tabla

```
data = data.dropna()
data.show()
data.createOrReplaceTempView("data_geo")
```

Seleccionar y graficar

```
%sql select `State Code`,
`2015 median sales price` from data_geo
```

Gráfico: mapa

Seleccionar y graficar

```
%sql select City,
`2014 Population estimate`/1000
as `2014 Population Estimate (1000s)`,
`2015 median sales price`
as `2015 Median Sales Price (1000s)`
from data_geo order by `
2015 median sales price` desc limit 10;
```

Gráfico: pie

Seleccionar y graficar

```
%sql select `State Code`,
`2015 median sales price`
from data_geo order by
`2015 median sales price` desc;
```

Gráfico: histograma

Seleccionar y graficar

```
%sql select `State Code`,
`2015 median sales price`
from data_geo where
`2015 median sales price` >= 300;
```

Gráfico: cuantiles

Seleccionar y graficar

```
%sql select `City`,
`State Code`,
`2015 median sales price`
from data_geo where
`2015 median sales price` >=
300 limit 20;
```

Gráfico: boxplot

Seleccionar y graficar

```
%sql select `State Code`,
`2015 median sales price`
from data_geo order by
`2015 median sales price` desc;
```

Gráfico: boxplot

Un poquito de Scala y ML

Crear directorio

```
%scala
val basePath = "/tmp/ejemplo-mllib-persistencia"
dbutils.fs.rm(basePath, recurse=true)
dbutils.fs.mkdirs(basePath)
```

Cargar datos de entrenamiento

```
entrenamiento = sqlContext.read.format("libsvm").\
option("numFeatures", "784").\
load("/databricks-datasets/mnist-digits/data-001/\
mnist-digits-train.txt")

entrenamiento.cache()

print("# de imagenes: %d " % entrenamiento.count())
```

Entrenar un clasificador

```
from pyspark.ml.classification import \
RandomForestClassifier
rf = RandomForestClassifier(numTrees=20)
modelo = rf.fit(entrenamiento)
```

Guardar modelo

```
basePath = "/tmp/ejemplo-mllib-persistencia"
modelo.save(basePath + "/modelo")
```

Guardar modelo

```
basePath = "/tmp/ejemplo-mllib-persistencia"
modelo.save(basePath + "/modelo")
```

Cargar modelo

```
%scala
import org.apache.spark.ml.classification
.RandomForestClassificationModel
val model = RandomForestClassificationModel
.load(basePath + "/modelo")
```

Probar el modelo

```
%scala
val test = sqlContext.read.format("libsvm")
.option("numFeatures", "784")
.load("/databricks-datasets/mnist-digits
/data-001/mnist-digits-test.txt")
```

Calcular y mostrar predicciones

```
%scala
val predicciones = model.transform(test)
display(predicciones.select("label", "prediction"))
```

Ejemplo: streaming estructurado

Cargar datos de archivos JSON

```
%fs ls /databricks-datasets/structured-streaming/events/
```

```
%fs head /databricks-datasets/structured-streaming/events/file-0.json
```

Cargar datos de archivos JSON en DataFrame

```
from pyspark.sql.types import *

inputPath = "/databricks-datasets\
/structured-streaming/events/"

jsonSchema = StructType([\
  StructField("time", TimestampType(), True), \
StructField("action", StringType(), True) ])

staticInputDF = spark.read.\
schema(jsonSchema).json(inputPath)

display(staticInputDF)
```

Crear DF estático con ventanas de observación

```
from pyspark.sql.functions import *

staticCuentasDF = staticInputDF.groupBy( \
staticInputDF.action, \
window(staticInputDF.time,"1 hour")) \
.count()

staticCuentasDF.cache()

staticCuentasDF.createOrReplaceTempView("cuentas")
staticCuentasDF.show()
```

Mostrar datos en función del tiempo

```
%sql select action,
date_format(window.end, "MMM-dd HH:mm") as time,
count from cuentas order by time, action
```

Emular Streaming y crear Dataframe

```
from pyspark.sql.functions import *

streamingInputDF = (
  spark
    .readStream
    .schema(jsonSchema)
    .option("maxFilesPerTrigger", 1)
    .json(inputPath)
)
```

Emular Streaming y crear Dataframe

```
streamingCuentasDF = (
  streamingInputDF
    .groupBy(
      streamingInputDF.action,
      window(streamingInputDF.time, "1 hour"))
    .count()
)
```

```
streamingCuentasDF.isStreaming
```

Definir query dinámica

```
query = (
  streamingCuentasDF
    .writeStream
    .format("memory")          # en memoria
    .queryName("counts")
    .outputMode("complete")    # todos los counts en la
    .start()
)
```

Explorar counts

Revisar resultados hasta el momento

```
%sql select action,
date_format(window.end, "MMM-dd HH:mm") as time,
count from counts order by time, action
```